

Дослідницький аналіз даних для онлайн-магазину

Дослідження ґрунтується на наборі даних, що містить інформацію про продажі товарів через різні канали трафіку та за браузерами, країнами, континентами та мовами користувачів.

Метою аналізу є виявлення ключових тенденцій у динаміці продажів, визначення категорій продукції, які забезпечують найбільший внесок у загальний дохід компанії, та дослідження взаємозв'язків між показниками в розрізі каналів, категорій і континентів із оцінкою їхньої статистичної значущості.

З детальними розрахунками можна ознайомитись **за посиланням:** [Google Colab](#)

Аналітичний дашборд знаходиться на [Tableau Public](#)

Набір даних складається з 349545 рядків і 18 колонок та має наступні характеристики:

- кількість колонок числового типу: 5 (`ga_session_id`, `account_id`, `is_verified`, `is_unsubscribed`);
- кількість колонок категоріального типу: 12 (`continent`, `country`, `device`, `browser`, `mobile_model_name`, `operating_system`, `language`, `channel`, `medium`, `category`, `name`, `short_description`);
- кількість колонок типу `datetime`: 1;
- кількість унікальних сесій: 349545;
- період часу, який розглядається: з 2020-11-01 до 2021-01-31;
- значення пропущені в колонках `language` (кількість - 114266), `account_id` (321600), `is_verified` (321600), `is_unsubscribed` (321600), `category` (316007), `name` (316007), `price` (316007), `short_description` (316007);
- більше пропущених значень в колонках, які стосуються інформації щодо реєстрації користувачів, в зв'язку з тим, що отриманий датасет містить загальну інформацію по всім сесіям (в кількості 349545), в т.ч. лише 27945 сесій, під час яких користувачі реєструвались, тобто інформація стосовно реєстрації міститься у 27945 рядках із 349545;
- крім того можна зазначити, що кількість сесій, під час яких зроблено замовлення складає 33538 (із 349545);
- дублікати відсутні.


Загальні тенденції

У періоді, що оцінюється, загальна сума продажів склала \$ 31,971,731.1.

Середня вартість замовлення дорівнювала \$ 953, мінімальна - \$ 3, максимальна - \$ 9585.

Загальна кількість замовлень становила 33538.


Вартість переважної кількості замовлень знаходиться в діапазоні від \$ 0 до \$ 479.25 . Кількість таких замовлень дорівнює 17492 , що складає 52.0 % від загальної кількості.




Малюнок 1. Розподіл розміру замовлень

Найбільший рівень доходу (\$ 17,665,280), як і кількість замовлень (18,553) принесли продажі споживачам на континенті Америка. В цілому, топ-3 континентами за розміром доходу є Америка, Азія та Європа. Середня вартість замовлення на цих континентах відрізняється несуттєво.


З основними показниками можна ознайомитись на малюнках 2, 3, 4.



Малюнок 2. Топ-3 континента за рівнем доходу




Малюнок 3. Топ-3 континента за кількістю замовлень




Малюнок 4. Середня вартість замовлення по топ-3 континентам


З основними показниками продажів в розрізі країн можна ознайомитись на малюнках 5, 6, 7. Сполучені Штати Америки займають перше місце, як за рівнем доходу (\$ 13,943,553), так і за кількістю замовлень (14673). Однак найбільший середній розмір замовлення зафіксовано у Франції (\$ 1,048).



Малюнок 5. Топ-5 країн за рівнем доходу



Малюнок 6. Топ-5 країн за кількістю замовлень



Малюнок 7. Середня вартість замовлення по топ-5 країнам

Найбільший дохід в США отримано від реалізації товарів категорії Sofa & armchairs (\$ 3,707,144.5) при загальній кількості їх замовлень в розмірі 1903.

index	category	revenue	count
1	Sofas & armchairs	3,707,144	1,903
2	Chairs	2,619,774	2,576
3	Beds	2,213,058	1,298
4	Bookcases & shelving units	1,567,607	3,374
5	Cabinets & cupboards	994,546	995
6	Outdoor furniture	929,245	984
7	Tables & desks	777,865	1,248
8	Chests of drawers & drawer units	382,388	616
9	Bar furniture	330,805	487
10	Children's furniture	207,575	752

Таблиця 1. Топ-10 категорій товарів за рівнем доходу у країні з найбільшим доходом (США)

Загальний (світовий) рейтинг категорій продукції за рівнем доходу також очолює категорія Sofas & armchairs (\$ 8,388,254.5).

index	category	revenue	count
1	Sofas & armchairs	8,388,254	4,301
2	Chairs	6,147,749	5,952
3	Beds	4,919,725	2,926
4	Bookcases & shelving units	3,640,818	7,630
5	Cabinets & cupboards	2,336,500	2,318
6	Outdoor furniture	2,142,222	2,229
7	Tables & desks	1,790,308	2,941
8	Chests of drawers & drawer units	906,562	1,452
9	Bar furniture	735,503	1,092
10	Children's furniture	467,697	1,702


Таблиця 2. Топ-10 категорій товарів за загальною сумою продажів

З повною інформацією щодо доходу в розрізі категорій та країн можна ознайомитись в таблиці 3.

country	United States	India	Canada	United Kingdom	France	Total
Sofas & armchairs	3707144.5	788430.0	692427.5	234812.0	187735.0	5610549.0
Chairs	2619773.8	544309.2	417740.8	188519.4	134029.4	3904372.6
Beds	2213058.0	358319.5	354772.0	133816.0	116414.0	3176379.5
Bookcases & shelving units	1567606.9	364507.4	278981.9	113987.6	73830.0	2398913.8
Cabinets & cupboards	994545.5	191888.0	181802.0	71684.5	59101.5	1499021.5
Outdoor furniture	929245.2	162289.4	185322.8	57002.4	40486.4	1374346.2
Tables & desks	777865.0	186157.5	132678.0	49374.0	42299.0	1188373.5
Chests of drawers & drawer units	382388.0	73111.0	71952.0	36784.0	21544.5	585779.5
Bar furniture	330805.0	57657.0	51724.0	22103.0	11199.0	473488.0
Children's furniture	207575.0	39177.0	30264.0	13348.0	14258.0	304622.0
Total	13730006.9	2765846.0	2397665.0	921430.9	700896.8	20515845.6

Таблиця 3. Загальні продажі за категоріями товарів (топ-10 категорій) у топ-5 країнах за рівнем доходу.


У розрізі девайсів максимальний дохід (\$ 18,864,039.0) та максимальну кількість замовлень (19,702) принесли користувачі десктопів (див. малюнки 8, 9).




Малюнок 8. Рівень доходу в розрізі девайсів

Малюнок 9. Кількість замовлень в розрізі девайсів

З показниками продажів в розрізі каналів можна ознайомитись на малюнках 10, 11.



Малюнок 10. Розподіл доходу в розрізі каналів



Малюнок 11. Кількість замовлень в розрізі девайсів

Кількість зареєстрованих користувачів за звітний період склала 27945 , із них 20036 (71.7 %) підтвердили свою електронну адресу та 4735 (16.9 %) відписалися від розсилки.

Середня вартість замовлень у користувачів, що відписалися від розсилки, склала \$ 965.8.

Середня вартість замовлень у користувачів, що не відписалися від розсилки, склала \$ 921.5.

Тобто факт відмови від розсилки повідомлень компанії не свідчить про зниження зацікавленості в продукції.

Найбільше зареєстрованих користувачів мешкають в США. В цілому користувачі зареєстровані у 108-ми країнах. З кількістю таких користувачів в топ-10 країнах та в розрізі континентів можна ознайомитись в таблицях 4, 5.


	country	number of registered users
1	United States	12,384
2	India	2,687
3	Canada	2,067
4	United Kingdom	859
5	France	553
6	Spain	536
7	Taiwan	500
8	China	490
9	Germany	490
10	Italy	386

Таблиця 4. Топ-10 країн за кількістю зареєстрованих користувачів.

	continent	number of registered users
1	Americas	15,520
2	Asia	6,664
3	Europe	5,170
4	Oceania	272
5	Africa	266
6	(not set)	53

Таблиця 5. Розподіл зареєстрованих користувачів за континентами

Динаміка загальної кількості сесій та сесій, в межах яких відбувались реєстрації користувачів та здійснювались замовлення, зображена на малюнку 12, їх розподіл в розрізі каналів та пристроїв - в таблицях 6, 7, дохід в розрізі каналів та пристроїв - в таблиці 8.



Малюнок 12. Динаміка сесій

channel	number_of_sessions	sessions_with_orders	sessions_with_registrations
Organic Search	124425	11921	10035
Paid Search	94341	9042	7467
Direct	81382	7800	6514
Social Search	27914	2716	2212
Undefined	21483	2059	1717

Таблиця 6. Загальна кількість сесій в розрізі каналів

device	number_of_sessions	sessions_with_orders	sessions_with_registrations
desktop	204429	19702	16417
mobile	137267	13113	10878
tablet	7849	723	650


Таблиця 7. Загальна кількість сесій в розрізі пристроїв

device	desktop	mobile	tablet	Total
channel				
Direct	4655	2985	160	7800
Organic Search	7011	4655	255	11921
Paid Search	5261	3574	207	9042
Social Search	1594	1065	57	2716
Undefined	1181	834	44	2059
Total	19702	13113	723	33538


Таблиця 7. Кількість сесій із замовленнями в розрізі каналів та пристроїв

Аналіз динаміки продажів

На малюнках 13-15 зображено динаміку доходів в цілому та у розрізі континентів, каналів, пристроїв.



Малюнок 13. Динаміка доходу (за день)




Малюнок 14. Динаміка доходу в розрізі континентів

Перевірка кореляції та p -value показує що продажі на топ-3 континентах сильно корелюють між собою:

price_Americas vs price_Europe: $r = 0.670$, $p\text{-value} = 0.00000$
 price_Americas vs price_Asia: $r = 0.692$, $p\text{-value} = 0.00000$
 price_Europe vs price_Asia: $r = 0.668$, $p\text{-value} = 0.00000$

Коефіцієнт r від 0.66 до 0.69 означає помірно сильну позитивну кореляцію. Тобто коли на одному континенті зростають продажі, на інших також схоже спостерігається зростання.
 $p\text{-value} = 0.00000$ (значно менше 0.05) - кореляція статистично значуща, тобто ці зв'язки мало ймовірно випадкові..
 Це може свідчити про глобальні тренди у продажах: наприклад, пікові дні чи сезонні ефекти впливають на всі континенти одночасно.



Малюнок 15. Динаміка доходу в розрізі каналів

Отримані результати кореляційного аналізу показують чітку позитивну кореляцію між продажами за різними каналами трафіку.


Пара каналів	r (коефіцієнт)	$p\text{-value}$	Висновок
Organic Search – Paid Search	0.808	0.00000	Сильна, статистично значуща кореляція
Organic Search – Direct	0.760	0.00000	Сильна, значуща
Organic Search – Social Search	0.434	0.00002	Помірна, значуща
Paid Search – Direct	0.724	0.00000	Сильна, значуща

Paid Search – Social Search	0.452	0.00001	Помірна, значуща
Direct – Social Search	0.462	0.00001	Помірна, значуща

Усі $p\text{-value} < 0.05$, отже, усі виявлені кореляції — статистично значущі.

Найвищі коефіцієнти кореляції Пірсона ($r \approx 0.8, 0.76, 0.72$) спостерігаються між Organic Search, Paid Search і Direct, що свідчить про спільні коливання продажів у цих каналах — можливо, через загальні маркетингові кампанії або сезонні піки.

Social Search демонструє помірну кореляцію ($r \approx 0.43\text{--}0.46$), тобто має дещо відмінну динаміку продажів — ймовірно, вплив соцмереж не збігається повністю з трендами інших каналів.



Малюнок 16. Динаміка доходу в розрізі категорій продукції

Кореляції та $p\text{-value}$ між категоріями товарів:

Sofas & armchairs vs Chairs: $r = 0.578$, $p\text{-value} = 0.00000$

Sofas & armchairs vs Beds: $r = 0.535$, $p\text{-value} = 0.00000$

Sofas & armchairs vs Bookcases & shelving units: $r = 0.666$, $p\text{-value} = 0.00000$

Sofas & armchairs vs Cabinets & cupboards: $r = 0.658$, $p\text{-value} = 0.00000$

Chairs vs Beds: $r = 0.554$, $p\text{-value} = 0.00000$

Chairs vs Bookcases & shelving units: $r = 0.637$, $p\text{-value} = 0.00000$

Chairs vs Cabinets & cupboards: $r = 0.573$, $p\text{-value} = 0.00000$

Beds vs Bookcases & shelving units: $r = 0.593$, $p\text{-value} = 0.00000$

Beds vs Cabinets & cupboards: $r = 0.515$, $p\text{-value} = 0.00000$

Bookcases & shelving units vs Cabinets & cupboards: $r = 0.539$, $p\text{-value} = 0.00000$


Усі коефіцієнти r знаходяться в межах 0.5–0.67, що свідчить про позитивну кореляцію (від помірної до сильної) між категоріями.

Усі p -value = 0.00000, тобто усі зв'язки статистично значущі ($p < 0.05$).


Це означає, що динаміка продажів одних категорій подібна до інших — зростання або спад в одній групі продукції часто супроводжується схожими змінами в інших.

В цілому на вищенаведених графіках динаміки доходу видно наявність сезонних патернів, імовірно, тижневої сезонності, коли активність клієнтів зростає у певні дні тижня. Крім того, фіксуються декілька значних сплесків активності клієнтів в середині грудня та на початку січня, які, ймовірно, пов'язані з акціями чи розпродажами.

Це підтверджується і наступними діаграмами, які надають дані щодо патернів продажів у розрізі днів тижня та місяців (малюнки 17, 18).




Малюнок 17. Загальний дохід в розрізі місяців



Малюнок 18. Загальний дохід в розрізі днів тижня.

Тісний взаємозв'язок рівня доходу та кількості сесій в день зображено на малюнку 19.



Малюнок 19. Кореляція кількості сесій та рівня доходу в день


Між цими показниками існує дуже сильна позитивна кореляція. Це підтверджується наступними статистичними коефіцієнтами:

`pvalue=np.float64(1.7394621412998283e-39)` - надзвичайно мале значення p-value, що свідчить про статистичну значущість кореляції. Тобто ймовірність того, що така кореляція випадкова, практично нульова.

Pearson Correlation: 0.9313146607045042 - дуже близько до 1, отже, чим більше сесій, тим більше продажів.


Рівень продажів та кількість сесій за день сильно пов'язані, і цей зв'язок дуже надійний.

Динаміку продажів в розрізі зареєстрованих та незареєстрованих користувачів зображено на малюнку 20.




Малюнок 20. Динаміка продажів в розрізі зареєстрованих та незареєстрованих користувачів

З метою проведення аналізу відмінностей між цими групами зроблено візуалізацію розподілу їх значень (малюнки 21, 22).



Малюнок 21. Розподіл щоденних продажів зареєстрованим користувачам




Малюнок 22. Розподіл щоденних продажів незареєстрованим користувачам

Враховуючи розмір вибірок, проведено тест Д'агостіно-Пірсона на визначення ступеню нормальності розподілу. Результати тесту свідчать що розподіл цих двох наборів даних суттєво відрізняється від нормального (для зареєстрованих користувачів $p\text{-value} = 0.01$, для незареєстрованих користувачів $p\text{-value} = 0.006$).


Оскільки обидві групи не є нормально розподіленими, для їх порівняння використано непараметричний тест Манна-Уїтні. Отриманий коефіцієнт $p\text{-value} = 0.00$ означає, що різниця між вибірками є статистично значущою.

Коефіцієнт кореляції Пірсона ($r = 0.659$) підтверджує досить сильний додатний зв'язок між продажами для зареєстрованих і незареєстрованих користувачів (Малюнок 23). Тобто, коли зростають продажі серед зареєстрованих, зазвичай зростають і серед незареєстрованих. Коефіцієнт $p\text{-value} = 0.00000$ показує, що результат статистично значущий, тобто визначений додатний зв'язок є не випадковим.



Малюнок 23. Щоденні продажі зареєстрованим користувачам vs Щоденні продажі незареєстрованим користувачам


Динаміка щоденної кількості сесій в розрізі каналів зображена на малюнку 24.



Малюнок 24 Динаміка щоденної кількості сесій в розрізі каналів трафіку

Стосовно кількості сесій за різними каналами трафіку можна зазначити наступне.

Розподіл значень щоденної кількості сесій в каналі Social Search є нормальним, що підтверджується тестом Д'агостіно-Пірсона ($p\text{-value} = 0.2144$) та відображається візуалізацією (Малюнок 25).



Малюнок 25. Розподіл щоденної кількості сесій через канал Social Search

Розподіл значень кількості сесій в розрізі інших каналів не є нормальним ($p\text{-value} < 0.05$).

Враховуючи вищевикладене, для подальшого аналізу взаємозв'язку між наборами даних використано тест Красскела–Уолліса (Kruskal–Wallis test), результати якого показали наявність статистично значущих відмінностей між групами ($p\text{-value} = 0.00$).


Для попарного порівняння груп використано тест Манна–Уїтні (Mann–Whitney U test). Отримані коефіцієнти ($p\text{-value} = 0.00$) показують статистично значущі відмінності між усіма групами.

Для визначення ступеню кореляції між групами визначались коефіцієнти кореляції Спірмана (Spearman correlation), оскільки нормальність розподілу не дотримується (за `normaltest`).

Всі коефіцієнти $r > 0.78$, більшість — навіть $0.9+$, що означає дуже сильний позитивний зв'язок між динамікою сеансів у різних каналах, тобто, коли кількість сесій у якомусь каналі зростає, вона майже завжди зростає й в інших. Усі $p\text{-value}$ значно менші, ніж 0.05 , що означає, що усі кореляції статистично значущі.

Динаміка кількості сесій між усіма каналами має сильний і статистично значущий позитивний зв'язок. Це свідчить, що коливання активності користувачів у різних каналах відбуваються синхронно — ймовірно, під впливом загальних факторів (сезонність, маркетингові кампанії, новини тощо).

Динаміка щоденної долі сесій з органічним трафіком у Європі та Америці зображена на малюнку 26.




Малюнок 26. Динаміка щоденної долі сесій з органічним трафіком у Європі та Америці

Для перевірки наборів даних на відповідність нормальному розподілу використано тест Д'агостіно-Пірсона, результати якого показали, що ці набори даних можна вважати нормальними ($p\text{-value}=0.506$ - Америка, $p\text{-value}=0.278$ - Європа).

Враховуючи це, для визначення ступеню кореляції застосовано тест Пірсона, результати якого свідчать про дуже слабкий позитивний зв'язок між змінними ($r=0.088$) при цьому зв'язок не є статистично значущим ($p\text{-value}=0.404$).

Відсутність взаємозв'язку між цими наборами даних можна побачити на малюнку 27.



Малюнок 27. Щоденна доля Organic Search в Америці vs Щоденна доля Organic Search в Європі

У результаті проведеного статистичного аналізу даних щодо динаміки сесій та продажів за різними континентами, каналами трафіку та категоріями продукції було встановлено таке:

1. Нормальність розподілу

Для більшості вибірок розподіл показників не відповідав нормальному закону (за тестом Д'Агостіно–Пірсона, $p < 0.05$), що зумовило використання непараметричних методів (зокрема, тесту Крускала–Волліса) для порівняння груп.

У випадках, коли вибірки мали нормальний розподіл, застосовувався параметричний аналіз (тест Пірсона, t-тест).

2. Порівняння континентів

Продажі між топ-3 континентами (Americas, Europe, Asia) виявили помірно сильну позитивну кореляцію ($r \approx 0.67\text{--}0.69$, $p < 0.001$), що свідчить про узгоджені тенденції змін попиту на різних ринках.

3. Порівняння каналів трафіку

Між основними каналами (Organic, Paid, Direct, Social) виявлено **високу позитивну кореляцію** ($r \approx 0.7\text{--}0.8$, $p < 0.001$), тобто зростання активності в одному каналі супроводжується підвищенням у решті. Це може свідчити про синергію маркетингових каналів.

4. **Порівняння категорій продукції**

Продажі між основними категоріями товарів також мають помірну позитивну кореляцію ($r \approx 0.5\text{--}0.6$, $p < 0.001$), що вказує на спільну сезонність або поведінкові закономірності споживачів.

5. **Зареєстровані vs незареєстровані користувачі**

Виявлено істотну позитивну кореляцію між продажами обох груп ($r \approx 0.66$, $p < 0.001$), що може відображати загальні тренди попиту незалежно від статусу користувача.

6. **Organic Search: Americas vs Europe**

Тест Пірсона ($r = 0.088$, $p = 0.404$) показав **відсутність статистично значущого зв'язку** між показниками двох регіонів — їхня динаміка, ймовірно, визначається різними ринковими умовами.

Загальний висновок

Аналіз показав наявність стійких позитивних взаємозв'язків між більшістю каналів, категорій і континентів, що свідчить про взаємопов'язану структуру продажів та трафіку.

Разом з тим, окремі ринки (зокрема, Americas та Europe у каналі Organic Search) демонструють незалежну поведінку, що може бути ознакою різних маркетингових або споживчих особливостей.

Отримані результати доцільно враховувати при плануванні кампаній, орієнтованих на конкретні регіони чи сегменти користувачів.